Υπολογιστική Νοημοσύνη
Εργαστηριακές Ασκήσεις ακ. έτους 2026-27

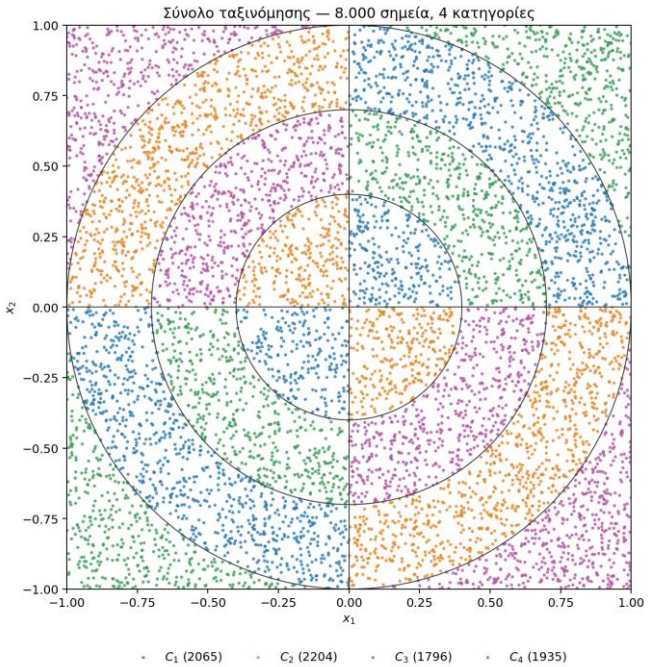
Η πρώτη άσκηση έχει βαρύτητα 20% και η δεύτερη 10%.

- Ομάδες με 2 ή 3 μέλη.
- **Δήλωση ομάδων**: **e-mail στον διδάσκοντα με (ΑΜ, ονοματεπώνυμο) μελών της ομάδας μέχρι 22 Νοεμβρίου 2026** (αυστηρή προθεσμία). Η δήλωση συνεπάγεται υποχρέωση υποβολής των εργασιών.
- **Προθεσμία υποβολής των εργασιών: Τετάρτη 9 Δεκεμβρίου 2026.**
- **Εξέταση εργασιών (διά ζώσης στο εργαστήριο): την εβδομάδα 14-18 Δεκεμβρίου 2026**
- Γλώσσα προγραμματισμού: **C ή Java (όχι Python).**
- Η υποβολή θα γίνει με χρήση της εντολής **turnin** ως εξής:

  turnin assignment@mye035 <your_filename>
- Δεκτές για εξέταση γίνονται μόνο ασκήσεις που είναι ολοκληρωμένες, δηλ. **τα προγράμματα θα πρέπει άμεσα να μεταγλωττίζονται και να εκτελούνται στους υπολογιστές του Τμήματος** (π.χ. opti3060ws03). Να αναφέρετε και την εντολή μεταγλώττισης για την παραγωγή του εκτελέσιμου από τον πηγαίο κώδικα.
- Θα δημιουργήσετε δύο καταλόγους, έναν για κάθε άσκηση. Κάθε κατάλογος θα περιλαμβάνει τον πηγαίο και τον εκτελέσιμο κώδικα της άσκησης, καθώς και ένα report (.pdf) με αποτελέσματα και συμπεράσματα σχετικά με την άσκηση. Υποβολές χωρίς report δεν βαθμολογούνται.
- Μην υποβάλετε συμπιεσμένα αρχεία .rar
- Θα πρέπει να υπάρχει πληροφορία για τα ονόματα και τα ΑΜ των μελών της ομάδας.

Εκφώνηση Ασκήσεων

Ασκηση 1: Πρόβλημα ταξινόμησης τεσσάρων κατηγοριών: Το σύνολο παραδειγμάτων του προβλήματος υπάρχει στο αρχείο classification_8000.txt. Θα χρησιμοποιήσετε 4000 παραδείγματα ως σύνολο εκπαίδευσης και τα υπόλοιπα 4000 παραδείγματα ως σύνολο ελέγχου.

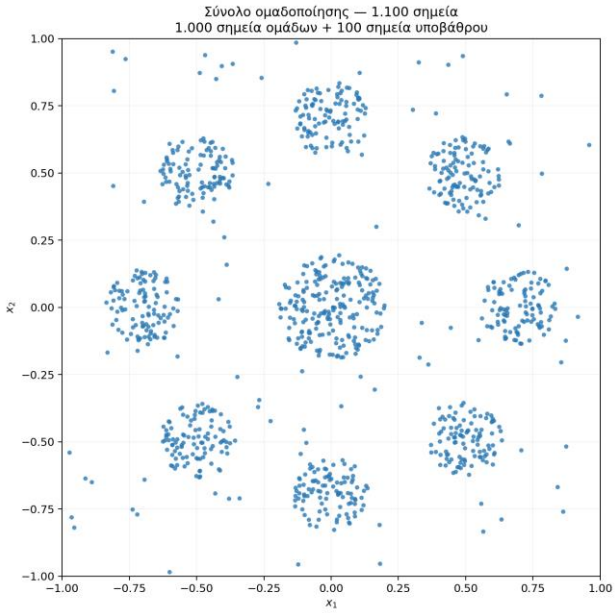


Να κατασκευάσετε τρία **πρόγραμματα ταξινόμησης** (ΠΤ1, ΠΤ2, ΠΤ3) βασισμένα στο **πολυεπίπεδο perceptron** (MLP) με **ένα , δύο και τρία κρυμμένα επίπεδα αντίστοιχα.**
Οι συναρτήσεις ενεργοποίησης ορίζονται ως εξής: i) στα κρυμμένα επίπεδα: υπερβολική εφαπτομένη (tanh(u)) ή relu και ii) για το επίπεδο εξόδου θα ορίσετε εσείς τη συνάρτηση ενεργοποίησης που απαιτείται για το συγκεκριμένο σύνολο παραδειγμάτων.
Κάθε πρόγραμμα και ανάλογα με τον αριθμό των κρυμμένων επιπέδων θα πρέπει να βασίζεται στις ακόλουθες μονάδες:
1) Με χρήση της εντολής define, καθορισμός αριθμού εισόδων (d), αριθμού κατηγοριών (K), αριθμού νευρώνων στο πρώτο κρυμμένο επίπεδο (H1), αριθμού νευρώνων στο δεύτερο κρυμμένο επίπεδο (H2), αριθμού νευρώνων στο τρίτο κρυμμένο (H3) και είδος συνάρτησης ενεργοποίησης για τα κρυμμένα επίπεδα.
2) Φόρτωμα των συνόλων εκπαίδευσης και ελέγχου (από αντίστοιχα αρχεία) και κωδικοποίηση των κατηγοριών (ορισμός των επιθυμητών εξόδων για κάθε κατηγορία).
3) Καθορισμός της αρχιτεκτονικής του δικτύου MLP. Ορισμός των απαιτούμενων πινάκων και άλλων δομών ως καθολικών μεταβλητών. Καθορισμός του ρυθμού μάθησης και του κατωφλίου τερματισμού. Τυχαία αρχικοποίηση των βαρών/πολώσεων στο διάστημα (-1,1).
4) Υλοποίηση της συνάρτησης forward-pass (float *x, int d, float *y, int K) η οποία υπολογίζει το διάνυσμα εξόδου y (διάστασης K) του MLP δοθέντος του διανύσματος εισόδου x (διάστασης d).
5) Υλοποίηση της συνάρτησης backprop(float *x, int d, float *t, int K) η οποία λαμβάνει τα διανύσματα x διάστασης d (είσοδος) και t διάστασης K (επιθυμητή έξοδος) και υπολογίζει τις παραγώγους του σφάλματος ως προς οποιαδήποτε παράμετρο (βάρος ή πόλωση) του δικτύου ενημερώνοντας τους αντίστοιχους πίνακες.
6) Χρησιμοποιώντας τα παραπάνω να υλοποιήσετε τον **αλγόριθμο εκπαίδευσης gradient descent και ενημέρωση των βαρών ανά ομάδες των L παραδειγμάτων (mini-batches) θεωρώντας τα N παραδείγματα του συνόλου εκπαίδευσης** (όπου το L διαιρέτης του N και ορίζεται στην αρχή του προγράμματος). Σημειώστε ότι εάν L=1 έχουμε σειριακή ενημέρωση, ενώ εάν L=N έχουμε ομαδική ενημέρωση.
Στο τέλος κάθε εποχής θα πρέπει υποχρεωτικά να υπολογίζετε και να τυπώνετε την τιμή του συνολικού σφάλματος εκπαίδευσης. Τερματίζουμε όταν η διαφορά της τιμής του σφάλματος εκπαίδευσης μεταξύ δύο εποχών γίνει μικρότερη από κάποιο κατώφλι, αφού όμως ο αλγόριθμος έχει τρέξει για τουλάχιστον 2000 εποχές.
7) Αφού τερματιστεί η εκπαίδευση του δικτύου να γίνεται υπολογισμός και εκτύπωση της **ικανότητας γενίκευσης** του δικτύου που προκύπτει, υπολογίζοντας το **ποσοστό σωστών αποφάσεων στο σύνολο ελέγχου**.

Να εξετάσετε και να **καταγράψετε σε ένα πίνακα** τη γενικευτική ικανότητα των δικτύων (ποσοστό επιτυχίας στο σύνολο ελέγχου) θεωρώντας:

- α) Συνάρτηση ενεργοποίησης στα κρυμμένα επίπεδα υπερβολική εφαπτομένη ή relu (ίδια για όλους του κρυμμένους νευρώνες ενός δικτύου)
- β) L= 100.
- γ) για ΠΤ1: H1 = 16, 32, 64, 128, για ΠΤ2: H1xH2 = 8x8, 16x16, 32x32, για ΠΤ3: H1xH2xH3 = 8x8x8, 16x16x16, 32x32x32 (συνολικά 2x10=20 εκπαιδεύσεις δικτύων)
- Για το δίκτυο με την καλύτερη γενικευτική ικανότητα που θα βρείτε, να τυπώσετε τα παραδείγματα του συνόλου ελέγχου χρησιμοποιώντας διαφορετικό στυλ (πχ + και -) ανάλογα με το αν το παράδειγμα ταξινομείται από το δίκτυο στη σωστή κατηγορία ή όχι.
- Μπορείτε να κάνετε κάποιο σχόλιο σχετικά με την θέση των σφαλμάτων;

Ασκηση 2: Πρόβλημα ομαδοποίησης εννέα ομάδων. Το σύνολο παραδειγμάτων του προβλήματος υπάρχει στο αρχείο clustering_1100.txt.



Να κατασκευάσετε **πρόγραμμα ομαδοποίησης με Μ ομάδες** (το Μ θα ορίζεται με την εντολή #define) βασισμένο στον **αλγόριθμο k-means**. Το πρόγραμμα θα φορτώνει το αρχείο με τα παραδείγματα, θα εκτελεί τον αλγόριθμο k-means με Μ κέντρα και στο τέλος θα αποθηκεύει τις συντεταγμένες των κέντρων των ομάδων. Η αρχική θέση κάθε κέντρου να γίνεται επιλέγοντας τυχαία κάποιο από τα παραδείγματα. Επίσης θα πρέπει στο τέλος να υπολογίζεται **και να τυπώνεται το σφάλμα ομαδοποίησης ως εξής: για κάθε παράδειγμα x_i υπολογίζουμε την Ευκλείδεια απόσταση $||x_i-\mu_k||^2$ από το κέντρο μ_k της ομάδας στην οποία ανήκει και αθροίζουμε τις αποστάσεις για όλα τα παραδείγματα x_i.**

Να εκτελέσετε το πρόγραμμα ομαδοποίησης στο δοθέν σύνολο παραδειγμάτων για Μ=3,5,7,9,11,13 ομάδες. Για **κάθε τιμή του Μ** να κάνετε τα εξής:

α) Να εκτελέσετε 50 τρεξίματα του προγράμματος με διαφορετικά (τυχαία επιλεγμένα αρχικά κέντρα), να τυπώνετε το σφάλμα ομαδοποίησης καθεμίας από τις 50 λύσεις, και να αποθηκεύσετε (τα κέντρα και την τμή σφάλματος) για τη **λύση με το μικρότερο σφάλμα ομαδοποίησης**, καθώς και την τιμή του σφάλματος.

β) Στη συνέχεια να εμφανίσετε (plot) στο ίδιο σχήμα τόσο τα παραδείγματα (π.χ. με '+') όσο και τις θέσεις των κέντρων που βρήκατε (π.χ. με '*').

γ) Βάσει των αποτελεσμάτων που βρήκατε, να φτιάξετε ένα διάγραμμα που να δείχνει πώς μεταβάλλεται το σφάλμα ομαδοποίησης με τον αριθμό των ομάδων. Μπορεί να χρησιμοποιηθεί το σφάλμα ομαδοποίησης για να εκτιμήσουμε τον πραγματικό αριθμό ομάδων; (στο σύνολό μας ο πραγματικός αριθμός των ομάδων είναι 9).

δ) **Το κριτήριο silhouette** θεωρείται ενα αρκετά αποτελεσματικό κριτήριο για την αξιολόγηση μιας λύσης του k-means και την εκτίμηση του πραγματικού αριθμού των ομάδων στο σύνολο παραδειγμάτων. Να υλοποιήσετε μια συνάρτηση που θα παίρνει ως είσοδο το σύνολο δεδομένων και μια λύση του k-means με Μ ομάδες και θα υπολογίζει την τιμή του κριτήριου silhouette για τη λύση αυτή θεωρώντας ευκλείδεια απόσταση μεταξύ των παραδειγμάτων.

Στη συνέχεια να υπολογίσετε την τιμή του silhouette για τις λύσεις με Μ=3,5,7,9,11,13 που βρήκατε προηγουμένως και να φτιάξετε ένα διάγραμμα που να δείχνει πώς μεταβάλλεται το κριτήριο silhouette με τον αριθμό των ομάδων Μ. Να εντοπίσετε την τιμή του Μ για την οποία το κριτήριο έχει τη μεγαλύτερη τιμή. Συμπίπτει αυτή η τιμή με τον πραγματικό αριθμό των ομάδων;